SENTINEL

Deteksi operasi pengaruh terkoordinasi di ruang siber sosial, dengan bukti yang bisa dipertanggungjawabkan

Menemukan jaringan akun yang bergerak serentak, berulang, dan seragam (buzzer, sockpuppet, spam judi online) lalu menjelaskan alasannya dalam Bahasa Indonesia untuk analis siber TNI AD.

94 % F1 pada komentar TikTok asli (held-out)	**100 %** precision: 0 akun organik dituduh	**8–18 %** F1 dua pendekatan umum pada data yang sama	**< 1 dtk** proses 1.700 post, tanpa GPU

Tim	**Ganesha8**
Demo online	`sentinel-kartika-cyber.streamlit.app`
Kode sumber	`github.com/GlgApr/sentinel-kartika-cyber`
Tanggal	November 2026

01 Ringkasan

Operasi pengaruh di media sosial Indonesia tidak lagi dilakukan satu akun. Puluhan akun palsu memposting narasi yang sama dalam hitungan menit agar terlihat seperti suara publik. Bagi TNI AD, wujudnya antara lain hoaks rekrutmen "jalur khusus" yang mencatut nama institusi, disinformasi yang memicu kepanikan, phishing berkedok bansos, dan jaringan spam judi online yang membanjiri kolom komentar.

SENTINEL tidak menghitung volume atau sentimen. SENTINEL mencari **bukti koordinasi**: sekelompok akun yang bertindak *serentak*, *berulang*, dan *seragam*. Setiap temuan dikemas sebagai berkas kasus berisi skor, alasan tertulis, barcode sinkronisasi, peta jaringan, bukti ber-hash SHA-256, dan laporan intelijen siap kirim. Keputusan akhir tetap di tangan analis.

> **Diuji di data asli, bukan hanya di atas kertas.** Versi awal SENTINEL menangkap **0** akun spam pada komentar TikTok asli. Setelah lima kelemahan ditemukan dan diperbaiki, versi yang kodenya dibekukan sebelum data baru ditarik mencapai **F1 94 % dengan precision 100 %** pada 2.002 komentar held-out. Dua pendekatan umum (filter teks kembar dan pemantau lonjakan) hanya 18 % dan 8 %, sambil menuduh 124 dan 1.617 akun yang tidak bersalah.

02 Masalah dan relevansi bagi TNI AD

Analis siber menghadapi tiga hambatan yang tidak terselesaikan oleh dashboard monitoring biasa:

1. **Viral organik dan viral rekayasa terlihat sama.** Berita gempa dan kampanye buzzer sama-sama menghasilkan lonjakan volume. Alat berbasis volume akan menandai keduanya, sehingga analis tenggelam dalam alarm palsu.
2. **Operator sengaja menghindari filter.** Teks divariasikan sedikit demi sedikit, ditulis dengan huruf unicode "fancy" (𝐆𝐀𝐌𝐄𝟏𝟗𝟏), angka dekoratif (❷❼), homoglyph (`VlKlNG27` untuk VIKING27), atau dieja terpisah (`u b e t 9 6`). Filter teks kembar meloloskannya.
3. **Temuan harus bisa dipertanggungjawabkan.** Sebagai institusi negara, TNI AD tidak boleh menuduh warga tanpa dasar dan harus netral terhadap opini politik. Skor "kotak hitam" tidak bisa dibawa ke pimpinan.

Skenario penggunaan

Ancaman	Yang dilakukan SENTINEL
Hoaks rekrutmen mencatut TNI AD	Menemukan kelompok akun yang serentak menyebar tautan pendaftaran palsu yang sama, lalu menyusun laporan dan bukti untuk take-down.
Astroturfing tagar pemicu panik	Membedakan tagar yang didorong jaringan terjadwal dari percakapan organik di waktu yang sama.
Phishing berkedok bansos	Menghubungkan akun-akun baru yang memutar domain phishing yang sama.
Jaringan spam judi online	Menangkap operasi yang memutar puluhan kode merek dengan templat tetap, termasuk yang menyebar berhari-hari tanpa posting serentak.

03 Solusi: alur kerja analis

Dashboard mengikuti alur alat investigasi CIB profesional: **antrean ancaman → berkas kasus → tindakan**.

1 · Sumber data
Tarik atau unggah
Data live TikTok, YouTube, X, Threads, Instagram, Mastodon; unggah CSV/JSON; skenario demo.

→

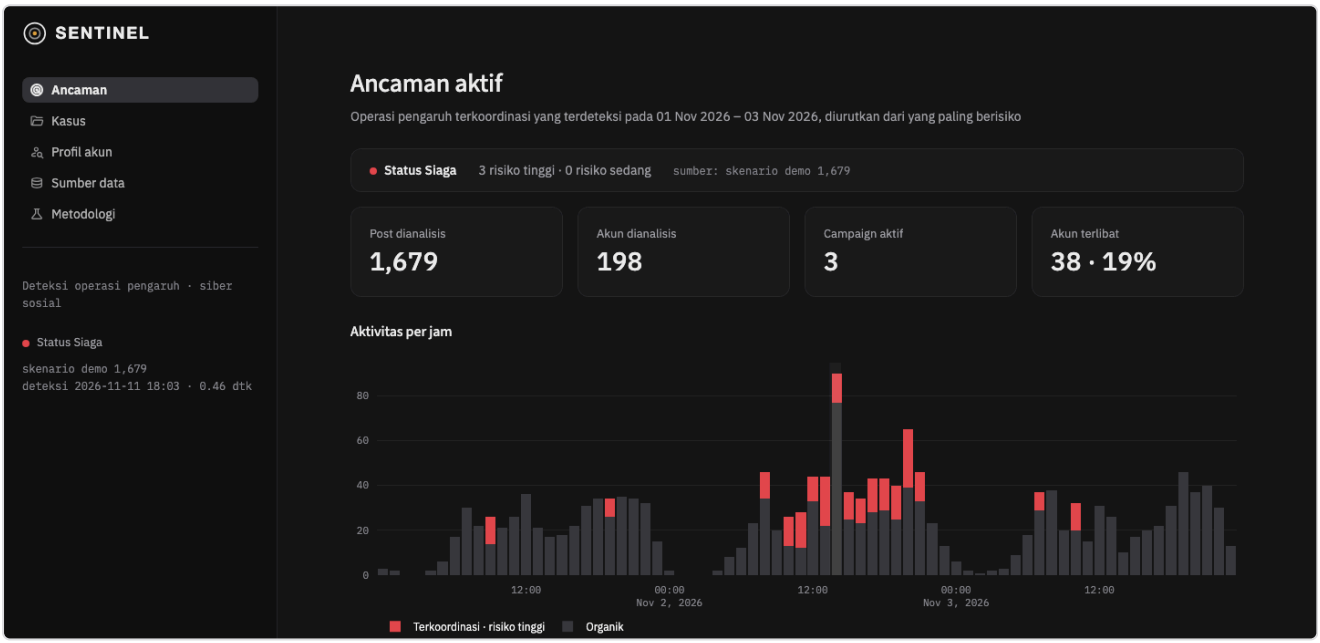
2 · Ancaman
Antrean terurut risiko
Status siaga, timeline organik vs terkoordinasi, kasus diurutkan skor.

→

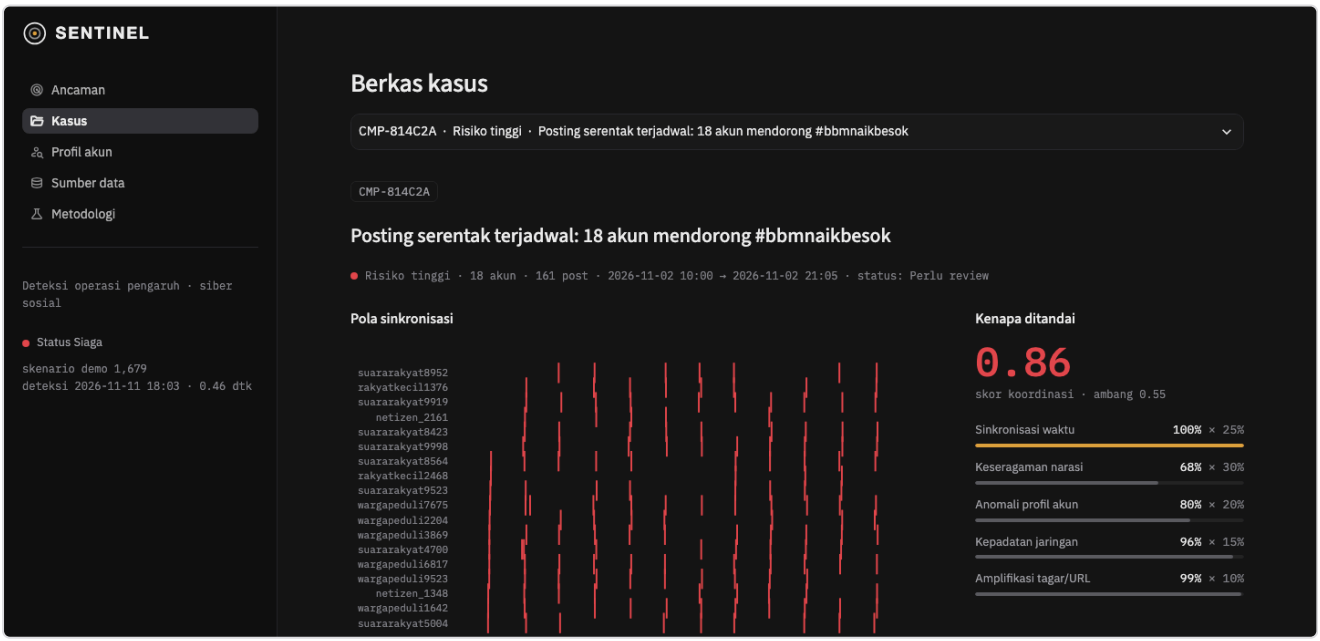
3 · Kasus
Bukti dan alasan
Skor 5 sinyal, barcode sinkronisasi, jaringan, akun, bukti + SHA-256.

→

4 · Tindakan
Keputusan analis
Tinjau, eskalasi, atau abaikan; laporan intelijen siap kirim.



Gambar 1. Halaman Ancaman. Batang merah adalah post dari jaringan terkoordinasi; lonjakan abu-abu tertinggi adalah berita gempa organik dan sengaja tidak ditandai.



Gambar 2. Berkas kasus. Barcode sinkronisasi (setiap garis satu post; garis yang berbaris vertikal berarti akun berbeda memposting di menit yang sama), kontribusi lima sinyal, dan temuan tertulis.

04 Cara kerja

SENTINEL menilai **perilaku**, bukan isi opini. Pertanyaannya bukan "apakah narasi ini benar?", tetapi "apakah sekelompok akun bertindak bersama dengan cara yang tidak terjadi secara alami?".

#	Tahap	Teknik	Alasan
1	Normalisasi	NFKC, angka dekoratif → angka biasa, semua aksara (Thai, Arab, ...) dipertahankan, kamus slang (`yg→yang`), kunci skeleton homoglyph	Menyamakan trik ejaan operator dan spammer
2	Representasi	TF-IDF char n-gram 3–5	Tahan typo dan parafrase ringan, tanpa GPU
3	Co-action	Jendela ≤ 20 menit: narasi mirip (cosine ≥ 0,60), URL sama, atau tagar/mention/kode merek langka sama	Koordinasi = aksi yang hampir bersamaan
4	Graf koordinasi	Edge hanya jika **berulang**: pasangan akun di ≥ 2 episode terpisah, atau motif (templat + target) sama di ≥ 2 gelombang	Satu kebetulan atau event viral tidak cukup
5	Operasi templat	Graf bipartit templat ↔ target; syarat rotasi (satu templat untuk ≥ 2 merek, atau satu merek lewat ≥ 2 templat)	Spam "tetes lambat" berhari-hari tanpa keserempakan
6	Clustering	Louvain + 2-core	Memisahkan operasi, membuang akun yang ikut secara kebetulan
7	Skor	Konten 30 %, waktu 25 %, profil akun 20 %, jaringan 15 %, amplifikasi 10 %; ambang 0,55, risiko tinggi ≥ 0,75	Skor transparan yang bisa dijelaskan
8	Triage	Keputusan analis tercatat, laporan, hash bukti	Manusia tetap memutuskan

Bila data profil akun tidak tersedia (misalnya data komentar), sinyal profil tidak dihitung dan bobot lain dinormalisasi ulang, sehingga "tidak tahu" tidak diperlakukan sebagai "normal".

05 Kebaruan

1. **Tidak butuh data latih, dan itu disengaja.** Model berlabel (seperti Botometer) hanya mengenali pola yang pernah dilihat dan mewarisi bias pelabelnya. Aturan perilaku SENTINEL langsung bekerja pada narasi baru hari ini dan netral terhadap opini.
2. **Kriteria "koordinasi berulang".** Inilah yang membedakan viral rekayasa dari viral organik: ribuan orang bisa membahas gempa di jam yang sama, tetapi tidak dengan kelompok yang sama berulang kali.
3. **Tiga pola operasi nyata**, semuanya ditemukan di data TikTok Indonesia: gelombang serentak, motif yang berulang lintas gelombang dengan kode berganti, dan operasi templat "tetes lambat" tanpa keserempakan.
4. **Dibuat untuk medsos Indonesia**: slang, kata ulang (`laki2` bukan kode merek), satuan (5kg), huruf unicode "fancy", angka dekoratif, homoglyph.
5. **Explainable dan siap pengadilan**: setiap skor punya alasan tertulis Bahasa Indonesia; bukti diunduh dengan sidik jari SHA-256 (*chain of custody*).
6. **Jujur terhadap batasnya**: kegagalan yang ditemukan saat pengujian dicatat terbuka (Bagian 06), bukan disembunyikan.

06 Hasil uji

a. Data asli: komentar TikTok Indonesia

±8.000 komentar publik dari 95 video (topik: TNI AD, rekrutmen, judi online, DPR, timnas, harga beras, dan lain-lain) ditarik lewat ScrapeCreators. Setiap akun spam diperiksa manual. Untuk uji akhir, **kode dibekukan dan hash-nya dicatat sebelum data baru ditarik**, sehingga tidak ada penyetelan pada data uji.

Metode (held-out, 2.002 komentar, 69 akun spam)	Precision	Recall	F1	Akun dituduh salah
SENTINEL	**100 %**	**88 %**	**94 %**	**0**
Filter teks kembar (duplicate filter)	13 %	28 %	18 %	124
Pemantau lonjakan (burst monitor)	4 %	99 %	8 %	1.617

Enam operasi judi online berbeda tertangkap. Di seluruh 8.000+ komentar **tidak ada akun organik yang dituduh**; slogan politik yang diulang banyak akun ("nkri harga mati" oleh 7 akun) tidak ditandai karena tidak ada bukti koordinasi, sementara filter teks kembar menuduh semuanya.

b. Perjalanan perbaikan

Versi	Yang ditemukan di data asli	Perbaikan
v1	**0 tertangkap.** Normalisasi membuang huruf Thai, emoji, dan unicode "fancy"; syarat pasangan berulang terlalu ketat karena yang berulang adalah kelompoknya	NFKC + semua aksara; mention/kode merek sebagai target; pengulangan level motif
v2	Skor operasi nyata 0,543 (lolos tipis); `laki2` terbaca kode merek; homoglyph tidak dikenali; recall 0 % pada spam "tetes lambat"	Amplifikasi diperluas; pengecualian kata ulang/satuan; kunci skeleton; detektor operasi templat
v3 (beku)	**Held-out: precision 100 %, recall 88 %, F1 94 %**	

c. Skenario sintetis berlabel (pagar regresi)

Tingkat penyamaran (rata-rata 5 seed)	SENTINEL F1	Burst monitor F1	Duplicate filter F1
0,0 (normal)	**100 %**	22 %	36 %
0,5	**100 %**	18 %	35 %
1,0 (operator sangat rapi)	**95 %**	16 %	34 %

d. Yang belum bisa (diungkap terbuka)

- **Skor per akun tidak andal.** Pada dataset bot Twitter berlabel Cresci-2017, skor buzzer per akun tidak lebih baik dari acak (AUC 0,32–0,55). Halaman *Profil akun* karena itu diposisikan sebagai lembar konteks; bukti yang sah adalah keanggotaan dalam operasi terkoordinasi.
- **Bot retweet tidak serentak** baru tertangkap 29 % (Cresci social spambots #1). Solusinya jaringan *co-share* lintas konten (Pacheco dkk., 2021), masuk rencana pengembangan.
- **Satu mode alarm palsu:** kerumunan asli yang menjawab satu akun pemancing di menit yang sama. Ini alasan setiap flag tetap melalui keputusan analis.
- Spam satu merek dengan satu templat sengaja tidak ditandai karena secara struktur sama dengan kutipan atau meme organik.

07 Kelayakan implementasi di satuan

Ringan dan bisa on-premise

- Python + SQLite, tanpa GPU dan tanpa layanan cloud berbayar. 1.700 post diproses kurang dari 1 detik di laptop biasa.
- Bisa dijalankan di jaringan tertutup satuan: data diunggah sebagai CSV/JSON dari alat pengumpul yang sudah dipakai.
- Instalasi satu perintah (`./run.sh`); 17 tes otomatis.

Terukur dan dapat diaudit

- Semua parameter (jendela waktu, ambang, bobot) ada di satu berkas konfigurasi.
- Setiap run deteksi tercatat; keputusan analis dipertahankan antar-run.
- Bukti ber-hash SHA-256 untuk keperluan hukum dan take-down.

Etika dan kepatuhan

- **Netral politik**: yang dinilai cara bertindak, bukan isi opini atau afiliasi.
- **Human-in-the-loop**: skor adalah rekomendasi; tidak ada tindakan otomatis terhadap akun.
- **Data pribadi**: demo memakai data sintetis fiktif. Mode Presentasi menyamarkan username dan tidak menyimpan avatar/URL. Data uji asli tidak disimpan di repositori (UU PDP, rulebook).

Rencana pengembangan

1. Lensa *co-share* untuk bot berbagi-ulang yang tidak serentak.
2. Konektor Telegram kanal publik dan mode near-real-time (per 5 menit) dengan notifikasi.
3. Embedding semantik Bahasa Indonesia (IndoBERT) untuk parafrase berat.
4. Deteksi gambar/meme duplikat (perceptual hash).
5. RBAC dan audit log untuk banyak analis.



Gambar 3. Jaringan koordinasi dalam satu kasus. Garis berarti dua akun ber-co-action di sedikitnya dua kesempatan berbeda; titik amber adalah akun penggerak (hub).

08 Teknologi dan atribusi

Komponen	Teknologi
Bahasa dan penyimpanan	Python 3, SQLite
Analisis teks dan graf	scikit-learn (TF-IDF), networkx (Louvain, k-core), pandas, numpy
Antarmuka	Streamlit, Plotly; desain mengikuti metode unslop (Damir Sokolovsky, CC BY 4.0)
Data live (opsional)	ScrapeCreators API (TikTok, YouTube, X, Threads, Instagram), Mastodon API publik
Dataset uji eksternal	Cresci-2017 (Cresci dkk., WWW 2017), hanya untuk evaluasi. Seluruh library open-source; kode deteksi dan dashboard dikembangkan tim selama program.